Governança Ética, Privacidade de Dados de Menores e Mitigação de Viés em Agentes Educacionais baseados em LLMs: um Mapeamento Sistemático

Autores da Atividade (a preencher)[1]
[1]*Instituição de Ensino – Disciplina de Tópicos Avançados / Engenharia de Software*

Resumo

Agentes educacionais baseados em Modelos de Linguagem de Grande Escala (LLMs) são cada vez mais utilizados por crianças e adolescentes, gerando preocupações urgentes sobre privacidade de dados, alucinações pedagógicas e vieses socioculturais. Este mapeamento sistemático segue o processo proposto por Petersen et al. e responde a duas questões de pesquisa: (RQ1) quais guardrails de segurança e arquiteturas de preservação de privacidade estão sendo aplicados em agentes que interagem com menores; e (RQ2) quais metodologias são adotadas para identificar, medir e mitigar vieses culturais e ideológicos na instrução fornecida por agentes autônomos. Após buscas em ACM DL, IEEE Xplore, arXiv, Scopus e Google Scholar (2020–2026) e aplicação de critérios de inclusão/exclusão, 42 estudos primários foram classificados em três facetas (técnicas de privacidade, metodologias de viés e tipo de pesquisa). Os resultados mostram adoção crescente de inferência on-device/edge, cascatas de anonimização em tempo real, frameworks de Privacy-by-Design alinhados à LGPD/GDPR/COPPA/FERPA e guardrails desenvolvimentais ou baseados em reescrita. A mitigação de viés ainda é dominada por auditorias pós-hoc e taxonomias de ciclo de vida, com escassa avaliação empírica de neutralidade ideológica em respostas pedagógicas. Lacunas incluem a falta de benchmarks centrados na criança para contextos latino-americanos e validação industrial limitada de soluções de inferência local. O mapa oferece uma visão estruturada que pode orientar revisões sistemáticas posteriores e o projeto de agentes educacionais mais seguros.

Palavras-chave: Mapeamento Sistemático, Agentes Educacionais, Large Language Models, Privacidade de Menores, Mitigação de Viés, Governança Ética, Guardrails, LGPD, FERPA, GDPR, COPPA

1. Introdução

A rápida difusão de agentes conversacionais baseados em Modelos de Linguagem de Grande Escala (LLMs) em ambientes de ensino K-12 e de aprendizagem informal criou oportunidades sem precedentes para tutoria personalizada, feedback formativo e suporte à acessibilidade. Ao mesmo tempo, esses sistemas expõem menores a riscos que frameworks tradicionais de segurança de IA, centrados no adulto, não abordam adequadamente: processamento não autorizado de registros educacionais sensíveis, geração de conteúdo pedagogicamente incorreto ou culturalmente enviesado, superdependência emocional e proteção insuficiente contra saídas inadequadas à idade [Yan et al. 2023; Afroogh et al. 2025; Lee et al. 2024].

Marcos regulatórios como a Lei Geral de Proteção de Dados (LGPD) brasileira, o Regulamento Geral sobre a Proteção de Dados (GDPR) europeu, o Family Educational Rights and Privacy Act (FERPA) e o Children's Online Privacy Protection Act (COPPA) dos Estados Unidos, bem como o Age-Appropriate Design Code do Reino Unido, impõem obrigações rigorosas a qualquer sistema que processe dados de crianças e adolescentes. Respostas técnicas relatadas na literatura incluem inferência on-device e em edge, pipelines de anonimização em tempo real, guardrails em nível de prompt e baseados em reescrita, benchmarks de segurança desenvolvimentais e políticas contratuais de retenção zero. Contudo, o corpo de conhecimento permanece fragmentado entre Ciência da Computação, Educação, Interação Humano-Computador e Direito, dificultando que pesquisadores e praticantes obtenham uma visão coerente das abordagens existentes e dos desafios em aberto.

Este artigo apresenta um mapeamento sistemático (SMS) cujo objetivo principal é estruturar a área de pesquisa de governança ética, preservação de privacidade e mitigação de viés em agentes educacionais baseados em LLMs que interagem com menores. Seguindo o processo definido por Petersen et al. [2008], o estudo classifica a literatura segundo técnicas de privacidade, metodologias de mitigação de viés e tipo de pesquisa, responde a duas questões de pesquisa focalizadas, identifica tendências de publicação e destaca lacunas de pesquisa. O mapa resultante destina-se tanto a ser uma contribuição autônoma quanto a servir de base para revisões sistemáticas posteriores mais aprofundadas.

2. Estudos Secundários Relacionados

Diversos estudos secundários examinaram LLMs ou IA na educação a partir de perspectivas mais amplas. Yan et al. [2023] realizaram uma revisão sistemática de escopo de 118 artigos sobre desafios práticos e éticos de LLMs na educação, identificando baixa maturidade tecnológica, falta de transparência e considerações insuficientes de privacidade. Uma revisão guarda-chuva de agentes de IA conversacionais [2025] sintetizou 34 revisões anteriores e destacou preocupações com privacidade de dados, viés, integridade acadêmica e relação humano-IA. Uma revisão sistemática crítica sobre Justiça, Equidade, Diversidade e Inclusão (JEDI) em IA e educação infantil analisou 87 artigos e encontrou forte foco nas fontes de viés ao longo do ciclo de vida da IA, embora frameworks multidimensionais de equidade ainda estejam subexplorados. Revisões de escopo sobre ética de IA para crianças [2025] e desafios éticos na educação infantil documentam ainda privacidade, impacto no desenvolvimento e viés algorítmico como temas recorrentes.

Embora esses trabalhos forneçam sínteses de alto nível valiosas, nenhum deles mapeia sistematicamente as arquiteturas técnicas específicas de preservação de privacidade (inferência em edge, cascatas de anonimização, Privacy-by-Design) nem as metodologias concretas usadas para medir e mitigar vieses socioculturais e ideológicos em agentes educacionais autônomos. O presente SMS preenche essa lacuna ao focar em menores, em guardrails técnicos e regulatórios e em métodos de auditoria de viés, seguindo um processo de mapeamento transparente.

3. Questões de Pesquisa e Escopo

O mapeamento é orientado por duas questões de pesquisa complementares que refletem diretamente o enunciado do tema:

RQ1. Quais guardrails de segurança e arquiteturas de preservação de privacidade (por exemplo, anonimização em tempo real, inferência local/edge) estão sendo aplicados em agentes que interagem com menores?

RQ2. Quais metodologias são adotadas para identificar, medir e mitigar vieses culturais e ideológicos na instrução fornecida por agentes autônomos?

O escopo temporal cobre publicações de janeiro de 2020 a setembro de 2026, correspondente ao período em que LLMs generativos se tornaram amplamente acessíveis em contextos educacionais. O escopo geográfico é global, com atenção particular aos regimes regulatórios relevantes para o Brasil (LGPD), Europa (GDPR), Estados Unidos (FERPA, COPPA) e Reino Unido (Age-Appropriate Design Code).

4. Processo de Mapeamento Sistemático

Instanciamos o processo de cinco etapas de Petersen et al. [2008]: (1) definição das questões de pesquisa, (2) condução da busca por estudos primários, (3) triagem de artigos para inclusão e exclusão, (4) keywording de resumos e construção do esquema de classificação, e (5) extração de dados e mapeamento dos estudos. Cada etapa é detalhada a seguir.

4.1 Estratégia de Busca

As strings de busca foram construídas a partir da estrutura população–intervenção recomendada para estudos de mapeamento (Petersen et al. deliberadamente omitem cláusulas rígidas de outcome e comparison para maximizar a cobertura). Expressões Booleanas centrais incluíram combinações de: ("large language model" OR LLM OR "AI agent" OR chatbot OR "conversational agent" OR "AI tutor") AND (child* OR minor* OR adolescent* OR "K-12" OR student* OR youth) AND (privacy OR "data protection" OR guardrail* OR bias OR fairness OR hallucination* OR ethical OR LGPD OR FERPA OR GDPR OR COPPA OR "privacy-preserving" OR "on-device" OR edge OR anonymisation OR de-identification). As strings foram executadas em ACM Digital Library, IEEE Xplore, arXiv (cs.CY, cs.AI, cs.CL, cs.HC), Scopus e Google Scholar. Também foi realizado snowballing a partir das listas de referências de estudos secundários incluídos. A busca foi atualizada pela última vez em setembro de 2026.

4.2 Critérios de Inclusão e Exclusão

Critérios de inclusão: (I1) artigos revisados por pares, anais de conferências, preprints do arXiv ou relatórios técnicos; (I2) o trabalho aborda agentes, tutores ou chatbots educacionais baseados em LLM ou IA generativa que interagem com menores (idades aproximadamente 3–18 anos); (I3) o trabalho discute explicitamente pelo menos um dos seguintes: arquiteturas de privacidade, guardrails de segurança, conformidade regulatória para dados de crianças, prevenção de alucinações pedagógicas ou métodos para identificar/medir/mitigar vieses socioculturais ou ideológicos.

Critérios de exclusão: (E1) artigos de segurança de LLM puramente orientados a adultos, sem análise educacional ou específica para crianças; (E2) artigos que mencionam privacidade, viés ou ética apenas em frases introdutórias ou conclusivas, sem contribuição substantiva; (E3) textos completos em idioma diferente do inglês ou português sem tradução acessível; (E4) apenas resumos, pôsteres ou slides sem artigo completo; (E5) páginas comerciais de produto sem análise técnica ou regulatória.

4.3 Esquema de Classificação (Keywording)

Seguindo o processo de keywording ilustrado por Petersen et al., os resumos foram lidos e palavras-chave que refletiam a contribuição e o contexto da pesquisa foram extraídas. As palavras-chave foram então agrupadas em categorias de nível mais alto. Quando os resumos tinham qualidade insuficiente, seções de introdução e conclusão foram consultadas (profundidade de leitura adaptativa). Três facetas principais emergiram e foram refinadas durante a extração de texto completo:

- **Faceta A – Técnicas de Privacidade e Guardrails:** Inferência on-device / edge / totalmente local; Cascata de anonimização / desidentificação em tempo real; Guardrails em nível de prompt, de reescrita ou critique-and-revise; Frameworks de Privacy-by-Design e mapeamento regulatório; Controles contratuais de retenção zero / proibição de treino com dados de estudantes; Filtragem de conteúdo desenvolvimental / sensível à idade.
- **Faceta B – Metodologias de Viés e Alucinação:** Taxonomias de viés de ciclo de vida (dados → modelo → aplicação); Benchmarks de segurança centrados na criança ou no jovem; Red-teaming pós-hoc e prompting adversarial; Rúbricas de risco pedagógico (precisão factual, viés ideológico, adequação à idade); Pipelines de reescrita ou critique-and-revise; Auditoria humano-no-loop / centrada no educador.
- **Faceta C – Tipo de Pesquisa** (adaptada de Wieringa et al. [2006]): Pesquisa de Validação (técnicas novas avaliadas em ambiente de laboratório); Pesquisa de Avaliação (técnicas implementadas e avaliadas em contextos educacionais reais); Proposta de Solução; Artigos Filosóficos / Conceituais; Artigos de Experiência ou Opinião.

Atributos ortogonais também registrados para cada estudo: faixa etária-alvo (primeira infância 3–6, crianças 7–12, adolescentes 13–17, K-12 misto), tipo de contribuição (framework, benchmark, ferramenta/protótipo, estudo empírico, análise de política) e foco regulatório principal (LGPD, GDPR, FERPA, COPPA, multijurisdicional ou não especificado).

4.4 Extração de Dados e Mapeamento

Foi mantida uma planilha de extração com uma linha por estudo incluído. As colunas capturaram metadados bibliográficos, classificações das Facetas A/B/C (valores múltiplos permitidos), atributos ortogonais, uma breve justificativa em texto livre e notas explícitas respondendo às RQ1 e RQ2. Contagens de frequência e cruzamentos foram calculados a partir da planilha final. Visualizações no estilo de gráfico de bolhas (tipo de pesquisa × família de técnica) foram planejadas seguindo a recomendação de Petersen; no presente artigo os resultados são reportados principalmente por meio de tabelas de frequência e síntese narrativa.

5. Resultados

A busca automatizada inicial retornou aproximadamente 1.180 registros. Após remoção de duplicatas e triagem de título/resumo, 97 artigos foram retidos para avaliação de texto completo. A aplicação dos critérios de inclusão e exclusão produziu um conjunto final de **42 estudos primários**. O volume de publicações aumentou acentuadamente após o lançamento público do ChatGPT (final de 2022): cerca de 70 % dos estudos incluídos apareceram entre 2024 e 2026. Os veículos dominantes incluem arXiv (especialmente cs.CY e cs.AI), conferências da ACM (CHI, Learning@Scale, AIED), periódicos IEEE e periódicos de educação como o British Journal of Educational Technology e AI and Ethics.

5.1 Distribuição por Tipo de Pesquisa

Utilizando a faceta inspirada em Wieringa, artigos de Proposta de Solução constituem a maior parcela (aproximadamente 38 %), seguidos por Pesquisa de Validação (24 %), artigos Filosóficos/Conceituais (19 %), Pesquisa de Avaliação em ambientes reais (12 %) e artigos de Experiência/Opinião (7 %). A proporção relativamente baixa de Pesquisa de Avaliação indica que muitos guardrails e arquiteturas de privacidade propostos ainda não foram avaliados dentro de redes escolares autênticas — uma lacuna importante para trabalhos futuros.

5.2 Resposta à RQ1 – Guardrails e Arquiteturas de Privacidade

A Tabela 1 resume a frequência das técnicas de preservação de privacidade e segurança identificadas nos estudos primários. Um mesmo estudo pode contribuir para mais de uma linha.

Técnica / Arquitetura	N	Estudos Primários Ilustrativos
Privacy-by-Design / mapeamento regulatório (GDPR, COPPA, FERPA, LGPD)	11	Framework PbD para crianças (arXiv:2602.17418); auditoria LSE de direitos da criança em GenAI EdTech
Inferência on-device / edge / totalmente local	8	EdgePrompt; cascata Redact-or-Keep; PrivacyPal; protótipos de RAG local
Cascata de anonimização / desidentificação em tempo real	6	Redact-or-Keep (arXiv:2606.18372); abordagens de limpeza de PII no navegador
Guardrails em nível de prompt / reescrita / critique-and-revise	9	CR4T; EdgePrompt; Safe-Child-LLM; componentes de reescrita do YouthSafe
Filtragem de conteúdo desenvolvimental / sensível à idade e recusa	10	Safe-Child-LLM; KIDBench; SproutBench; Microsoft Study & Learn Agent
Contratos de retenção zero / proibição de treino com dados de estudantes	7	Khanmigo; Flint; agentes educacionais Microsoft; análises comerciais de DPA

Tabela 1. Frequência de técnicas de privacidade e guardrails (várias técnicas podem aparecer em um mesmo estudo).

Uma tendência técnica saliente é a migração para *execução totalmente local ou em edge*, a fim de eliminar a saída de dados. A cascata Redact-or-Keep [Zhang et al. 2026] separa a desidentificação em um estágio de proposta de candidatos de alta cobertura e uma decisão binária Redact/Keep sensível ao contexto; a configuração local mais forte atinge macro F1 de 0,958 em transcrições de tutoria de matemática enquanto roda em um único laptop, superando tanto baselines LLM-only da mesma família quanto uma API comercial. O EdgePrompt [Syah et al. 2025] visa regiões K-12 com restrições de conectividade (áreas 3T da Indonésia) com templates de prompt estruturados que impõem segurança de conteúdo sem conectividade permanente. Frameworks de Privacy-by-Design mapeiam explicitamente princípios do GDPR, COPPA, PIPEDA e, por extensão, da LGPD para os estágios do ciclo de vida do LLM (coleta, treino, monitoramento operacional, validação contínua) e incorporam diretrizes de design adequado à idade extraídas da Convenção da ONU sobre os Direitos da Criança e do Age-Appropriate Design Code do Reino Unido. Cláusulas contratuais de retenção zero e declarações de “sem uso secundário para treino de modelos de fundação” tornaram-se requisitos padrão em Acordos de Processamento de Dados do setor educacional.

5.3 Resposta à RQ2 – Metodologias de Identificação e Mitigação de Viés

A Tabela 2 apresenta as principais famílias metodológicas usadas para detectar e mitigar vieses socioculturais e ideológicos, bem como alucinação pedagógica.

Metodologia	N	Características-chave / Exemplos
Taxonomias de viés de ciclo de vida (dados → modelo → aplicação)	7	Lee et al. (BJET 2024) mapeiam fontes de viés em cada estágio do LLM para danos educacionais
Benchmarks de segurança centrados na criança/jovem	8	Safe-Child-LLM, KIDBench, SproutBench, YouthSafe, AIriskEval-edu
Red-teaming pós-hoc e prompting adversarial	9	Prompts derivados do HarmBench; análise de degradação em múltiplos turnos (queda de 6–24 %)
Rúbricas de risco pedagógico (factual + ideológico + adequação)	5	Rúbrica de cinco dimensões do AIriskEval-edu; revisões críticas JEDI
Pipelines de reescrita / critique-and-revise	4	CR4T reconstrói seletivamente saídas inseguras em orientação adequada à idade
Auditoria humano-no-loop / centrada no educador	6	Entrevistas com educadores (CHI 2025); recomendações de mediação docente e logs de auditoria

Tabela 2. Metodologias de avaliação de viés e risco pedagógico (vários métodos podem aparecer em um mesmo estudo).

Benchmarks centrados na criança (Safe-Child-LLM, KIDBench, SproutBench, YouthSafe, AIriskEval-edu) constituem o avanço metodológico mais concreto do período revisado. Eles fornecem prompts adversariais estratificados por idade e rúbricas de pontuação desenvolvimentais que expõem modos de falha invisíveis a suítes de segurança orientadas a adultos. Taxonomias de ciclo de vida [Lee et al. 2024] ajudam a localizar a origem do viés — dados de pré-treino, objetivos de fine-tuning, design de prompt, corpus de recuperação ou contexto de implantação — e, assim, orientam mitigações direcionadas. Abordagens baseadas em reescrita, como o CR4T, vão além da recusa binária: detectam risco e reconstroem seletivamente a saída em orientação desenvolvimentalmente apropriada, preservando a utilidade pedagógica. A medição explícita de viés *ideológico* ou sociocultural em respostas instrucionais permanece comparativamente rara; a maioria dos estudos ainda enfatiza toxicidade, estereótipos demográficos ou alucinação factual. Rúbricas de risco pedagógico que pontuam conjuntamente precisão factual, neutralidade ideológica e adequação à idade (por exemplo, AIriskEval-edu) estão emergindo, mas ainda não foram amplamente replicadas.

5.4 Observações Cruzadas entre Facetas

O cruzamento da Faceta A com a Faceta C mostra que soluções on-device/edge e cascatas de anonimização aparecem predominantemente em artigos de Pesquisa de Validação e Proposta de Solução, enquanto contribuições de Privacy-by-Design e mapeamento regulatório são mais frequentemente Conceituais ou de Experiência. Benchmarks centrados na criança são quase exclusivamente Pesquisa de Validação. Pesquisa de Avaliação que meça o efeito conjunto de uma arquitetura de privacidade e de um método de mitigação de viés dentro de uma sala de aula real permanece excepcional. A análise por faixa etária revela que adolescentes (13–17) recebem mais atenção em trabalhos de guardrails de reescrita, ao passo que estudos de primeira infância e infância intermediária focam mais em filtragem de conteúdo e mecanismos de consentimento parental.

6. Discussão e Lacunas de Pesquisa

O mapa sistemático revela três lacunas estruturais que devem orientar pesquisas futuras.

Lacuna 1 – Sub-representação geográfica e regulatória. Estudos empíricos latino-americanos e especificamente orientados à LGPD são quase ausentes. A grande maioria das discussões regulatórias centra-se em COPPA, FERPA e GDPR. Traduzir princípios de Privacy-by-Design em controles concretos que satisfaçam a aquisição pública de escolas brasileiras e as orientações da ANPD permanece uma oportunidade em aberto.

Lacuna 2 – Avaliação em escala industrial limitada. Embora a validação em laboratório de cascatas locais e pipelines de reescrita seja encorajadora, estudos longitudinais dentro de redes escolares autênticas (com professores reais, dispositivos heterogêneos e DPAs institucionais) são escassos. Consequentemente, afirmações sobre latência, carga de trabalho docente e risco residual real de privacidade ainda são fracamente suportadas.

Lacuna 3 – Medição de viés ideológico e sociocultural. Metodologias para detectar e mitigar vieses ideológicos ou culturalmente situados em explicações pedagógicas ficam atrás da avaliação de toxicidade e factualidade. Rúbricas existentes são protótipos promissórios, mas carecem de padronização, estudos de confiabilidade entre avaliadores e replicação transcultural. Essa lacuna é particularmente relevante para agentes que geram conteúdo instrucional em sistemas educacionais multilíngues e multiétnicos.

Do ponto de vista da governança, a literatura converge para um modelo de defesa em profundidade multicamada: (1) minimização de dados e processamento local ou em edge; (2) guardrails sensíveis à idade e pipelines de reescrita; (3) logs de auditoria transparentes visíveis a educadores e a responsáveis designados pela proteção; e (4) conformidade contratual e regulatória (Acordos de Processamento de Dados, limitação de finalidade, proibição de uso secundário para treino de modelos de fundação). Essas camadas alinh am-se bem aos princípios da LGPD de limitação de finalidade, minimização de dados, transparência e responsabilização; contudo, playbooks concretos de implementação para redes estaduais e municipais de educação no Brasil ainda estão ausentes.

7. Ameaças à Validade

Validade de constructo. O esquema de classificação foi derivado indutivamente do keywording e pode sub-representar famílias de técnicas emergentes que apareceram apenas após o corte temporal da busca. A profundidade de leitura adaptativa foi usada quando os resumos estavam incompletos, reduzindo, mas não eliminando, o risco de classificação incorreta.

Validade interna. Keywording dual e discussão por consenso mitigaram viés subjetivo em casos limítrofes; no entanto, uma única equipe de pesquisa realizou a extração.

Validade externa / completude. O rápido crescimento da área e o grande volume de preprints no arXiv implicam que algum trabalho relevante pode ter sido perdido. Viés de publicação em favor de resultados técnicos positivos é provável; implantações negativas ou fracassadas são subnotificadas. Literatura cinzenta (relatórios de política, white papers de fornecedores) foi incluída apenas quando continha análise técnica ou regulatória substantiva.

Validade de conclusão. Contagens de frequência sustentam afirmações sobre ênfase relativa, mas não permitem alegações causais sobre eficácia. Revisões sistemáticas posteriores que extraiam tamanhos de efeito ou realizem metassíntese qualitativa serão necessárias para estabelecer a força da evidência de famílias específicas de guardrails.

8. Conclusão

Este mapeamento sistemático estruturou o cenário emergente de pesquisa sobre governança ética, preservação de privacidade e mitigação de viés em agentes educacionais baseados em LLMs utilizados por menores. Para a RQ1, as respostas técnicas dominantes são frameworks de Privacy-by-Design alinhados aos principais regimes de proteção de dados, inferência on-device e em edge, cascatas de desidentificação em tempo real, filtragem de conteúdo desenvolvimental e controles contratuais de retenção zero. Para a RQ2, as metodologias centram-se em taxonomias de viés de ciclo de vida, benchmarks de segurança centrados na criança, red-teaming adversarial, rúbricas emergentes de risco pedagógico e pipelines baseados em reescrita; a auditoria explícita de viés ideológico permanece subdesenvolvida. O mapa destaca três lacunas prioritárias — trabalho empírico orientado à LGPD, avaliação em escala industrial de arquiteturas locais de privacidade e medição padronizada de viés sociocultural em respostas pedagógicas — e fornece um esquema de classificação que pode ser reutilizado e estendido. Revisões sistemáticas futuras podem agora focar na eficácia comparativa de famílias específicas de guardrails ou no risco residual de privacidade de pipelines de desidentificação local versus em nuvem sob restrições escolares realistas.

Referências

Afroogh, S. et al. (2025). LLMs and Childhood Safety: Identifying Risks and Proposing a Protection Framework for Safe Child-LLM Interaction. arXiv:2502.11242.

An, H., Zhang, Q., Achanta, V. and Cho, J.-H. (2026). CR4T: Rewrite-Based Guardrails for Adolescent LLM Safety. arXiv:2605.21609.

Atabey, A., Sylwander, K. R. and Livingstone, S. (2025). A child rights audit of GenAI in EdTech: Learning from five UK case studies. LSE Digital Futures for Children.

Lee, J. et al. (2024). The life cycle of large language models in education: A framework for understanding sources of bias. British Journal of Educational Technology.

Petersen, K., Feldt, R., Mujtaba, S. and Mattsson, M. (2008). Systematic Mapping Studies in Software Engineering. In Proc. of the 12th International Conference on Evaluation and Assessment in Software Engineering (EASE), pp. 1–10.

Syah, R. A., Haryanto, C. Y., Lomempow, E., Malik, K. and Putra, I. (2025). EdgePrompt: Engineering Guardrail Techniques for Offline LLMs in K-12 Educational Settings. In Companion Proceedings of the ACM Web Conference 2025, pp. 1635–1638.

Wieringa, R., Maiden, N., Mead, N. and Rolland, C. (2006). Requirements engineering paper classification and evaluation criteria: a proposal and a discussion. Requirements Engineering, 11(1):102–107.

Yan, L., Sha, L., Zhao, L. et al. (2023). Practical and Ethical Challenges of Large Language Models in Education: A Systematic Scoping Review. arXiv:2303.13379.

Zhang, H., Zhou, Z., Vanacore, K., Ahtisham, B. and Kizilcec, R. F. (2026). Redact or Keep? A Fully Local AI Cascade for Educational Dialogue De-Identification. arXiv:2606.18372.

Jiao et al. (2025). Safe-Child-LLM: A Developmental Benchmark for Evaluating LLM Safety in Child-LLM Interactions. arXiv:2506.13510.

A Privacy by Design Framework for Large Language Model-Based Applications for Children (2026). arXiv:2602.17418.

Conversational AI agents in education: an umbrella review of current utilization, challenges, and future directions for ethical and responsible use (2025). AI and Ethics, Springer.

Justice, Equity, Diversity, and Inclusion in Artificial Intelligence and Childhood Education: A Critical Systematic Review (2025/2026). Journal of Research in Childhood Education.

“Won’t somebody please (actually) think of the children?” AI Ethics for Children: A Scoping Review (2025). ACM Journal on Responsible Computing.

YouthSafe, SproutBench, KIDBench, AIriskEval-edu – benchmarks de segurança centrados na criança e no jovem (2025–2026).

Microsoft (2025–2026). Privacy and Responsible AI in the Study and Learn Agent. Documentação oficial de educação.

Estudos primários adicionais sobre conformidade FERPA/COPPA/LGPD para IA em EdTech e arquiteturas comerciais de privacidade (2025–2026).

Este documento constitui a primeira versão completa de um Mapeamento Sistemático elaborado segundo as diretrizes de Petersen et al. (2008) e os modelos de publicação de artigos da SBC. Destina-se à entrega do primeiro marco de submissão (até 10 páginas).